

Implementasi Metode Backpropagation Untuk Peramalan Luas Area Terbakar di Hutan dengan Inisialisasi Bobot Nguyen-Widrow

Afrizal Aminulloh¹, Sigit Adinugroho², Ahmad Afif Supianto³

Progam Studi Teknik Informatika, Fakultas Ilmu Komputer, Universitas Brawijaya
Email: ¹afrizal.aminulloh@gmail.com, ²sigit.adinu@ub.ac.id, ³afif.supianto@ub.ac.id

Abstrak

Bencana kebakaran hutan merupakan suatu peristiwa serius yang harus diwaspadai bagi daerah yang didominasi oleh kawasan hutan. Dalam kebakaran hutan terdapat beberapa faktor yang bisa memengaruhi terjadinya kebakaran seperti: suhu, kelembapan, hujan, angin dan lain lain. Paper ini mengimplementasikan metode backpropagation untuk meramalkan luas area kebakaran. Input yang digunakan berupa faktor yang memengaruhi terjadinya kebakaran hutan berjumlah 7 faktor. Proses metode backpropagation diawali dengan melakukan normalisasi data input dengan range berdasarkan fungsi aktivasi yang digunakan, setelah itu inisialisasi bobot dan bias menggunakan algoritme Nguyen-Widrow, melakukan proses *feed forward* dan dilanjutkan pada proses selanjutnya yaitu *feed backward* dengan syarat MSE kurang dari batas *error* atau iterasi kurang dari sama dengan iterasi maksimalnya, jika syarat sudah terpenuhi hasil output akan dinormalisasi, akan mendapat nilai peramalan, dan proses terakhir menghitung hasil SMAPE sebagai hasil dari keberhasilan proses peramalan. Berdasarkan hasil pengujian yang telah dilakukan didapatkan parameter optimal yaitu pada *neuron hidden layer* berjumlah 5, *learning rate* 0,1 dan iterasi maksimum 1500. Hasil rata-rata SMAPE tertinggi dari penelitian ini adalah 49,1796 dan rata-rata SMAPE terendah adalah 31,4492 yang menunjukkan bahwa metode backpropagation dapat digunakan untuk melakukan peramalan area terbakar di hutan.

Kata kunci: peramalan, luas area terbakar hutan, jaringan syaraf tiruan, backpropagation.

Abstract

Forest fires are a serious event that must be watched out for areas dominated by forest areas. In forest fires, there are several factors that can affect the occurrence of fires such temperature, humidity, rain, wind, and others. This paper implements the backpropagation method to predict the area of the fire. The input used is a factor that influences the occurrence of 7 forest fires. The process of backpropagation method begins with normalizing input data with a range based on the activation function used, after that initialization is weighted and can use the Nguyen-Widrow algorithm, feeds the feedforward and continues to the next process, feedbackward with the MSE requirement less than the error or iteration limit. less than the same as the maximum iteration, if the requirements have been met the output will be normalized, will get a forecasting value, and the last process calculates the results of MSE and SMAPE as a result of the success of the forecasting process. Based on the results of the tests that have been done, it is obtained that the optimal parameters are 5 hidden layer neurons, 0.1 learning rate, and maximum 1500 iterations. The highest average SMAPE result from this study is 49,1796 and the lowest SMAPE average is 31,4492 which shows that the backpropagation method can be used to forecast burn areas in the forest.

Keywords: forecasting, forest burnt area, artificial neural network, backpropagation.

1. PENDAHULUAN

Hutan merupakan suatu kesatuan ekosistem berupa hamparan lahan berisi sumber daya alam hayati yang didominasi pepohonan dalam area alam di lingkungannya, yang satu dengan

lainnya tidak dapat dipisahkan (menurut Undang Undang Nomor 41 tahun 1999). Kebakaran hutan menjadi perhatian internasional sebagai isu lingkungan dan ekonomi, khususnya setelah bencana El Nino yang menhanguskan lahan hutan seluas 25 juta hektar di seluruh dunia. Kebakaran dianggap sebagai ancaman yang

berpotensi untuk memengaruhi pembangunan karena efek secara langsung pada ekosistem (Rasyid, 2014). Dampak negatif yang ditimbulkan oleh kebakaran hutan cukup besar mencakup kerusakan ekologis, menurunnya keanekaragaman hayati, merosotnya nilai ekonomi hutan dan produktivitas tanah, perubahan iklim mikro maupun global, dan asapnya mengganggu kesehatan masyarakat serta mengganggu transportasi baik darat, sungai, danau, laut dan udara. Mengingat dampak dari kebakaran hutan tersebut, maka upaya perlindungan terhadap kawasan hutan dan tanah sangatlah penting.

Dengan mengadopsi sistem FWI (*Fire Weather Index*) dari Kanada yang dirancang pada tahun 1970, sehingga hanya dibutuhkan perhitungan sederhana menggunakan tabel dengan tulisan dari empat pengamatan meteorologi (yaitu suhu, kelembapan relatif, hujan, dan angin) yang dikumpulkan oleh stasiun cuaca (Morais, 2011).

Indonesia sebagai salah satu negara dengan keanekaragaman hayati tertinggi di dunia. Berdasarkan data FAO tahun 2010 hutan dunia termasuk di dalamnya hutan Indonesia secara total menyimpan 289 gigaton karbon dan memegang peranan penting menjaga kestabilan iklim dunia. Berdasarkan catatan kementerian Kehutanan Republik Indonesia, sedikitnya 1,1 juta hektar atau 2% dari hutan Indonesia menyusut tiap tahunnya (WWF, 2010). Pengurangan tersebut juga disebabkan oleh kebakaran hutan yang menyebabkan penurunan keanekaragaman hayati yang berada di hutan, dengan mengetahui luas area dan lokasi tempat kebakaran akan mempermudah dalam penentuan prioritas area hutan dan lokasi yang rentan terjadi kebakaran bisa dilakukan penjagaan ekstra untuk mencegah kerugian yang berlebih dan pelestarian sumber daya alam. Dari permasalahan tersebut dibutuhkan suatu sistem peramalan untuk meramalkan luas area terbakar di hutan, yang bisa digunakan untuk meramalkan kondisi hutan tergantung dari kisaran luas area kebakaran dalam satuan hektar. Dengan mengetahui hasil peramalan, akan mempermudah peninjauan lanjutan berdasarkan dampak kebakaran yang dialami untuk memperkecil persentase kebakaran di Indonesia.

Dari penelitian yang pernah dilakukan sebelumnya oleh (Jauhari, et al., 2016), (suhartanto, et al., 2017), (Hansun, 2013), dan (Dewi & Muslikh, 2013) bisa dikatakan bahwa metode backpropagation sangat baik untuk

digunakan dalam pengenalan pola data yang rumit dan dari keempat penelitian tersebut didapat akurasi yang baik.

Kelemahan dari metode backpropagation adalah lamanya iterasi yang harus dilakukan. Backpropagation tidak dapat memberikan kepastian mengenai berapa iterasi yang harus dilakukan untuk mencapai kondisi terbaik. Bobot awal akan menentukan apakah jaringan mencapai titik minimum lokal atau global, dan seberapa cepat konvergensinya. Bobot awal yang digunakan di metode backpropagation tidak boleh terlalu besar dikarenakan akan menyebabkan nilai turunan fungsinya menjadi sangat kecil, oleh karena itu dalam standar backpropagation bobot dan bias diisi dengan bilangan acak kecil, dikarenakan kondisi tersebut Nguyen-Widrow dapat mengatasi inisialisasi bobot yang lebih kecil dan akan mempercepat iterasi (Siang, 2009), Nguyen-Widrow merupakan algoritme yang digunakan untuk melakukan inisialisasi bobot awal pada JST untuk mengurangi waktu pelatihan (Andrian, 2014).

Metode Backpropagation yang telah dijelaskan di atas dapat diterapkan dalam memprediksi suatu keadaan yang akan datang. Sedangkan inisialisasi Nguyen-Widrow dapat digunakan untuk inisialisasi bobot terbaik untuk peramalan. Pada penelitian ini penulis akan memprediksi luas lahan hutan yang terbakar dengan metode Jaringan Syaraf Tiruan *Backpropagation* dengan memadukan algoritme inisialisasi Nguyen-Widrow pada proses inisialisasi bobotnya. Tujuannya adalah untuk mengetahui apakah algoritme inisialisasi Nguyen-Widrow dapat mengurangi waktu pelatihan, memberikan efisiensi, dan juga meningkatkan hasil peramalan terbaik

2. METODE DAN PEMBAHASAN

Metode JST *Backpropagation* merupakan metode untuk mengenali suatu pola yang rumit dan menghasilkan pengenalan pola yang baik. Backpropagation merupakan salah satu metode yang memiliki lapisan tersembunyi (hidden layer) bernilai satu atau lebih dan memiliki proses feed forward yang digunakan untuk peramalan dan proses kedua feed backward yang digunakan untuk pengecekan error dari proses sebelumnya yang nantinya akan dilakukan perbaikan pada proses selanjutnya.

2.1 Normalisasi

Normalisasi merupakan penyerdehanaan range data dengan jangkauan nilai tertentu. Normalisasi berfungsi untuk menyesuaikan *range output* fungsi aktivasi yang digunakan. Jika menggunakan fungsi aktivasi sigmoid, data masukan harus dirubah ke dalam *range* [0-1]. Namun, pada fungsi kontinu nilai 0 dan 1 tidak pernah tercapai sehingga *range* dirubah menjadi [0,1-0,9]. Normalisasi menggunakan Persamaan (1). (Martina, 2013).

$$\text{Normalisasi} = \frac{x - \min}{\max - \min} * (\omega - \alpha) + \alpha \quad (1)$$

Keterangan :

min : nilai minimum dari atribut

max : nilai maksimum dari atribut

ω : nilai terbesar pada range baru

α : nilai terkecil pada range baru

2.2 Algoritme Nguyen-Widrow

Nguyen-Widrow adalah sebuah algoritme yang digunakan untuk inisialisasi bobot pada jaringan syaraf tiruan untuk mengurangi waktu pelatihan. Algoritme inisialisasi Nguyen-Widrow adalah sebagai berikut (Siang, 2009) :

a. Set :

N = jumlah unit input

P = jumlah unit tersembunyi

β = faktor skala = $0.7(p)^{1/n} = 0.7 \sqrt[n]{p}$ (2)

b. Untuk setiap unit tersembunyi ($j = 1, \dots, p$), lakukan tahap (c) – (f)

c. Untuk $i = 1, \dots, n$ (semua unit input), $v_{ij}(\text{old})$ = bilangan acak antara

-0.5 dan 0.5

d. Hitung nilai $\|v_j(\text{old})\| = \sqrt{v_1^2 j + v_1^2 j a + \dots + v_n^2 j}$ (3)

e. Hitung bobot baru $V_{ij} = \frac{\beta v_{ij}(\text{old})}{\|v_j\|}$ (4)

f. Bias yang dipakai sebagai inisialisasi:

v_{oj} = bilangan acak antara $-\beta$ dan β .

2.3 Langkah-langkah Algoritme Backpropagation

Berdasarkan (Hansun, 2013).

Langkah 1 : Inisialisasi bobot dan bias dengan angka random yang terletak antara 0 dan 1

(tergantung fungsi aktivasi yang digunakan)

Langkah 2 : Jika kondisi stop belum terpenuhi lakukan langkah 3-10

Langkah 3 : Untuk setiap data training, lakukan langkah 4-9

Propagasi Maju (feedforward)

Langkah 4 : Setiap unit input ($X_i, i = 1, \dots, n$) akan menuju input layer dan menyebarkan sinyal tersebut pada hidden layer.

Langkah 5 : Menghitung nilai dari setiap *hidden unit* ($Z_j, j = 1, \dots, p$)

$$z_{in_j} = v_{oj} + \sum_{i=1}^n x_i v_{ij} \quad (5)$$

Menghitung dengan menggunakan sigmoid biner :

$$z_j = f(z_{in_j}) = \frac{1}{1 + \exp(-z_{in_j})} \quad (6)$$

Langkah 6: menghitung hasil dari unit output ($Y_k, K = 1, \dots, m$)

$$y_{in_k} = w_{ok} + \sum_{j=1}^p z_j w_{jk} \quad (7)$$

Menghitung menggunakan sigmoid biner :

$$y_k = f(y_{in_k}) = \frac{1}{1 + \exp(-y_{in_k})} \quad (8)$$

Propagasi Mundur (*backpropagation of error*)

Langkah 7 : menghitung faktor koreksi error dari bobot unit hidden layer (z_j) ke unit keluaran (y_k)

$$\delta_k = (t_k - y_k) f'(y_k) \quad (9)$$

Menghitung koreksi error bobot yang nantinya digunakan untuk memperbaiki bobot baru

$$\Delta w_{jk} = a \delta_k z_j \quad (10)$$

Menghitung koreksi error bias yang nantinya digunakan untuk memperbaiki bias baru

$$\Delta w_{ok} = a \delta_k \quad (11)$$

Langkah 8 : menghitung faktor koreksi error dari unit input (x_i) ke unit *hidden layer* (z_j)

$$\delta_{in_j} = \sum_{k=1}^m \delta_k w_{jk} \quad (12)$$

Kemudian hasilnya dikalikan dengan turunan dari fungsi aktivasi unit hidden layer (z_j)

$$\delta_j = \delta_{injf'}(z_j) \quad (13)$$

Menghitung koreksi error bobot yang nantinya digunakan untuk memperbaiki bobot baru

$$\Delta v_{ij} = a\delta_j x_i \quad (14)$$

Menghitung koreksi error bias yang nantinya digunakan untuk memperbaiki bias baru

$$\Delta v_{0j} = a\delta_j \quad (15)$$

Update Bobot dan Bias (*adjustment*)

Langkah 9 : Setiap unit *output* ($Y_k, k = 1, \dots, m$) akan memperbarui bias dan bobot dari setiap *hidden unit* ($j = 0, \dots, p$)

$$w_{0k}(\text{baru}) = w_{0k}(\text{lama}) + \Delta w_{0k} \quad (16)$$

$$w_{jk}(\text{baru}) = w_{jk}(\text{lama}) + \Delta w_{jk} \quad (17)$$

Demikian pula untuk setiap *hidden unit* ($Z_j, j = 1, \dots, p$) akan memperbarui bias dan bobot dari setiap unit *input* ($i = 0, \dots, n$)

$$v_{0j}(\text{baru}) = v_{0j}(\text{lama}) + \Delta v_{0j} \quad (18)$$

$$v_{ij}(\text{baru}) = v_{ij}(\text{lama}) + \Delta v_{ij} \quad (19)$$

2.4 Denormalisasi

Denormalisasi merupakan pengembalian range data yang telah dinormalisasi sebelumnya menjadi range data yang asli. Denormalisasi menggunakan persamaan di bawah ini :

$$\text{Denormalisasi} = \frac{(x' - a)(\text{max} - \text{min})}{\omega - a} + \text{min} \quad (20)$$

Keterangan :

x' = nilai keluaran dari pelatihan

ω = Batas maksimum

min = data minimum

max = data maksimum

2.5 Perhitungan Error MSE

Mean Squared Error (MSE) adalah metode yang digunakan untuk mengevaluasi hasil peramalan. Masing-masing kesalahan dikuadratkan dan rata-rata selisih kuadrat antara nilai yang diramalkan dan yang diamati (Jauhari, et al., 2016). MSE digunakan sebagai nilai error yang dihitung untuk data yang telah didenormalisasi dari hasil perhitungan menggunakan metode *backpropagation* dengan inisialisasi bobot Nguyen-Widrow

Rumus untuk perhitungan MSE adalah sebagai berikut :

$$\text{MSE} = \sum_{t=1}^n \frac{(\text{target} - y)^2}{n} \quad (21)$$

Keterangan :

MSE = Mean Square Error

N = Jumlah Sampel

target = Nilai actual

y = Nilai Prediksi

2.6 Perhitungan Akurasi SMAPE

SMAPE (*Symmetric Mean Absolute Percentage Error*) merupakan pendekatan yang dilakukan ketika besar variable ramalan digunakan sebagai evaluasi ketetapan ramalan. SMAPE adalah alternatif dari Mean Absolute Percentage Error (MAPE) bila ada permintaan nol untuk data peramalannya (Flores, 1986).

$$\text{SMAPE} = \frac{100}{n} \sum_{t=1}^N \frac{|F_t - X_t|}{(X_t + F_t)/2} \quad (22)$$

Keterangan :

F_t = nilai data ke-t

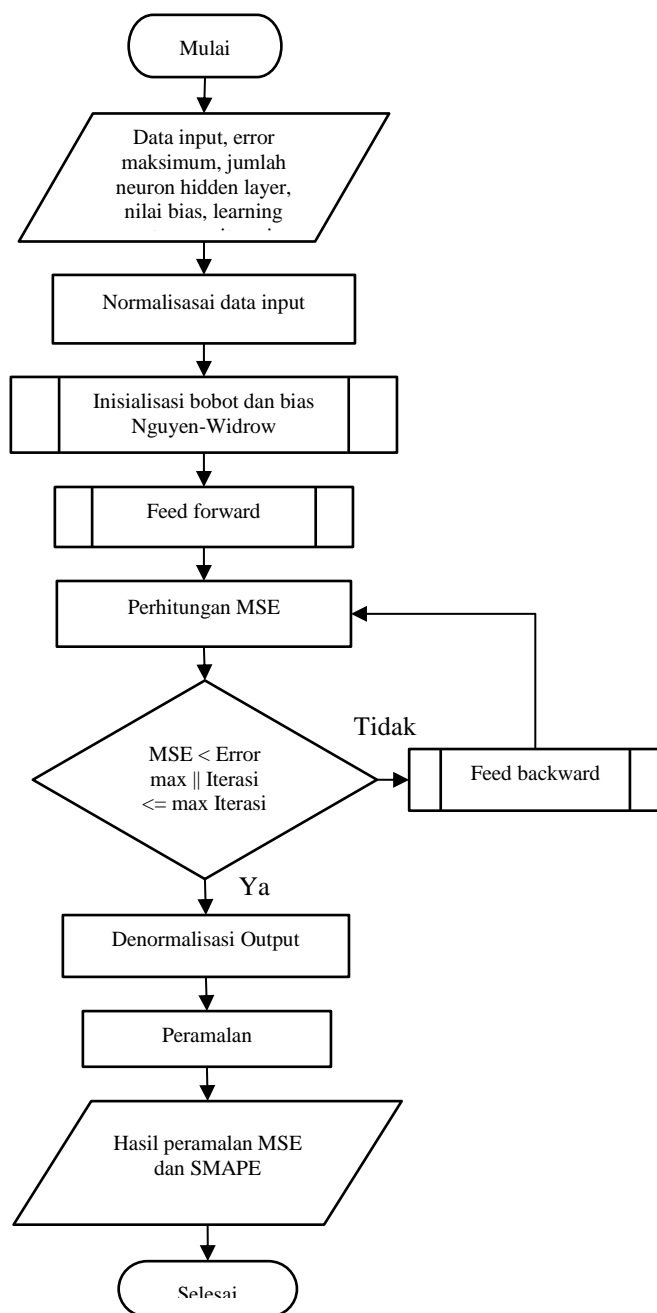
X_t = nilai ramalan ke-t

n = jumlah data

3. PERANCANGAN SISTEM

Sistem yang dibuat akan menggunakan model Jaringan Syaraf Tiruan sebagai mesin peramalan untuk meramal luas area lahan yang terbakar. Langkah pertama kali dilakukan adalah proses inisialisasi bobot dan diteruskan dengan proses pelatihan untuk mencari suatu bobot yang optimal yang digunakan untuk melakukan proses peramalan.

Setelah itu dilanjutkan dengan proses pelatihan data menggunakan metode backpropagation, jika sudah didapat bobot terbaik akan dilanjutkan ke proses peramalan dan perhitungan akurasi. Tahapan prosesnya ditampilkan dalam *flowchart* pada gambar 1.



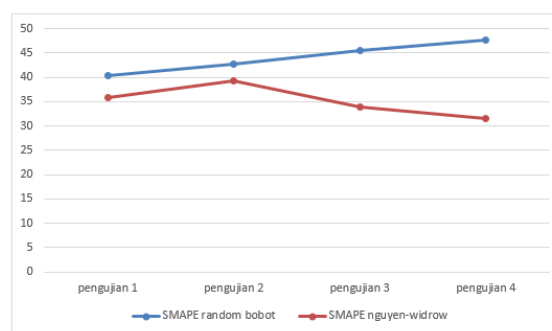
Gambar 1. Flowchart Perancangan Sistem

4. HASIL DAN PEMBAHASAN

Pada pengujian yang dilakukan penelitian ini terdapat 4 pengujian diantaranya adalah pengujian perbandingan bobot acak dan Nguyen-Widrow, pengujian perbandingan jumlah data latih dan data uji, pengujian parameter (jumlah *neuron hidden layer*, *learning rate*, dan iterasi). Pengujian dilakukan dengan rata-rata akurasi sebagai acuan utama dalam penilaian pada pengujian ini.

4.1 Pengujian Perbandingan Bobot Acak dan Nguyen-Widrow

Pada pengujian ini dilakukan perbandingan antara bobot acak dan algoritme Nguyen-Widrow untuk mengetahui perbandingan terbaik dan mengetahui apakah dengan algoritme Nguyen-Widrow bisa mempercepat pelatihan yang dapat meningkatkan hasil peramalan. Untuk pengujianya menggunakan data 80% data latih : 20% data uji dan parameter learning rate 0,1, jumlah *neuron hidden layer* 10, *max* iterasi 1000, *error max* 0,01.




Gambar 2. Grafik Pengujian Perbandingan Bobot Acak dan Nguyen-Widrow

dapat dilihat bahwa pada pengujian dengan nilai rata-rata terendah terdapat pada rata-rata SMAPE 31,5736 dengan menggunakan nguyen-widrow, dan nilai rata-rata tertinggi terdapat pada rata-rata SMAPE 47,5674.

Dari kedua grafik dapat dilihat bahwa dari semua percobaan pengujian Nguyen-Widrow lebih unggul dikarenakan memiliki rata-rata SMAPE yang lebih kecil daripada rata-rata SMAPE bobot acak dan dapat dinyatakan bahwa inisialisasi bobot Nguyen-Widrow dapat meningkatkan dan mengoptimalkan pada fase pelatihan data di *backpropagation*.

4.2 Pengujian Pengaruh Jumlah Iterasi Maksimum Terhadap SMAPE

Pada pengujian ini akan dilakukan dengan menggunakan 5 macam jumlah iterasi yaitu 100, 500, 1000, 1500, dan 2000. Untuk parameter yang digunakan adalah nilai learning rate 0,1, data yang digunakan 50% data latih dan 50% data uji, minimum error 0,1, dan jumlah *neuron hidden layer* 10. Pada setiap iterasi dilakukan 5 kali percobaan dan dihitung rata-rata dari ke 5 percobaan tersebut.




Gambar 3. Grafik Pengujian Pengaruh Jumlah Iterasi Maksimum Terhadap SMAPE

Hasil dari pengujian bisa dilihat pada gambar 2 dengan nilai rata-rata SMAPE terendah 34,4396 pada iterasi 1500 dan rata-rata SMAPE tertinggi 49,1796 pada iterasi 500.

Dari hasil analisis grafik bisa diketahui bahwa jika jumlah iterasi yang digunakan kurang maka tidak akan bisa melakukan pelatihan jaringan sepenuhnya sehingga tidak akan mendapatkan nilai optimal dan jika nilai iterasinya besar maka akan terjadi overfitting walaupun hasil *error* kecil (Sinha, et al., 2009).

4.3 Pengujian Pengaruh Nilai *Learning Rate* Terhadap SMAPE

Pada pengujian pengaruh *learning rate* terhadap tingkat akurasi akan diuji nilai *learning rate* dalam rentang 0,1 hingga 0,9. Data yang digunakan 50% data latih dan 50% data uji, jumlah iterasi maksimum yang digunakan adalah 1000, maksimum *error* 0,01, dan jumlah *neuron hidden layer* 10. Dan dilakukan 5 kali percobaan dan dihitung rata-rata dari ke 5 percobaan tersebut.



Gambar 4. Grafik Pengujian Pengaruh Learning Rate Terhadap SMAPE


Hasil dari pengujian bisa dilihat pada gambar 3 dengan nilai rata-rata SMAPE cenderung naik turun mengikuti kenaikan *learning rate*.

Semakin besar nilai *learning rate* akan menyebabkan nilai rata-rata SMAPE yang akan terus menurun tergantung dari *learning rate* nya.

Dari hasil grafik diatas dapat diketahui bahwa dalam jaringan syaraf tiruan backpropagation, *learning rate* dapat memiliki efek yang signifikan dalam menentukan hasil akurasi dengan tingkat *learning rate* kecil atau besar (Andries, 2007). Jika nilai *learning rate* terlalu besar algoritme akan kesulitan dan dapat menghasilkan nilai yang tidak stabil, jika nilai *learning rate* terlalu kecil akan menyebabkan konvergensi menjadi sangat lambat sehingga membutuhkan iterasi yang besar untuk mencapai SMAPE terbaik (Abbas, et al., 2010).

4.4 Pengujian Pengaruh Jumlah *Neuron Hidden Layer* Terhadap SMAPE

Pada pengujian ini menggunakan *neuron hidden layer* dengan rentang dari 5-25 *hidden layer*. Data yang digunakan 50% data latih dan 50% data uji, jumlah iterasi maksimum yang digunakan adalah 1000, menggunakan *learning rate* 0,1, dan maksimum *error* 0,01.



Gambar 5. Grafik Pengujian Pengaruh Jumlah *Neuron Hidden Layer* Terhadap SMAPE


Hasil dari pengujian bisa dilihat pada gambar 4 dengan bahwa nilai rata-rata SMAPE dari setiap percobaan pengujian jumlah *neuron hidden layer* yang dimana pada pengujian kedua mengalami kenaikan dan percobaan selanjutnya mengalami penurunan secara terus menerus.

Dari hasil analisis grafik bisa diketahui ketika jumlah *neuron hidden layer* meningkat maka kinerja dari algoritme backpropagation akan meningkat secara bertahap. Tetapi seiring peningkatan jumlah *neuron hidden layer* akan mengakibatkan kompleksitas jaringan syaraf dalam proses pelatihannya (Asthana, et al.,

2017). Jadi jika *neuron hidden layer* bertambah akan menyebabkan SMAPE lebih baik, tetapi jika *neuron hidden layer* terlalu besar maka akan memengaruhi proses pengenalan pola dan akan mencapai *overfitting* sehingga hasil SMAPE jadi tinggi.

4.5 Pengujian Nilai Perbandingan Jumlah Data Terhadap SMAPE

Pada pengujian perbandingan jumlah data latih Pengujian dilakukan dengan membandingkan data latih dan data uji dengan 4 jenis perbandingan yaitu 85% data latih : 15% data uji, 70% data latih : 30% data uji, 60% data latih : 40% data uji, 50% data latih : 50% data uji. Pengujian untuk masing-masing perbandingan dilakukan 4 variasi data dan masing-masing dilakukan 5 kali percobaan.



Gambar 6. Grafik Pengujian Perbandingan Jumlah Data Terhadap SMAPE

Hasil dari pengujian bisa dilihat pada gambar 2 dengan nilai rata-rata SMAPE terendah 36,441 pada perbandingan data latih dan data uji 80%:20% dan akurasi terendah 41,7902 perbandingan data latih dan data uji 50%:50%.

Secara umum seiring jumlah data pelatihan yang digunakan lebih besar akan menghasilkan proses peramalan yang lebih baik (Moyo & Sibanda, 2015).

5. KESIMPULAN

Peramalan area hutan yang terbakar dilakukan sesuai dengan tahapan peramalan yang sudah dirancang, pada penelitian ini memiliki tahapan yang terdiri dari proses inisialisasi bobot dan bias data yang diawali dengan normalisasi data, inisialisasi bobot dengan algoritme Nguyen-Widrow, setelah itu menuju proses training data dengan menggunakan metode backpropagation, setelah di dapatkan bobot dan bias terbaik dilanjutkan

pada proses pengujian serta proses denormalisasi dan terakhir evaluasi hasil peramalan.

Hasil SMAPE terbaik dari penelitian ini adalah 31,4492 didapatkan dengan parameter jumlah *neuron hidden layer* 5, *learning rate* 0,1, maksimum *error* 0,01, dan maksimum iterasi 1000.

Hasil perbandingan dari menggunakan bobot random dan Nguyen-Widrow didapatkan dengan hasil bahwa inisialisasi bobot menggunakan nguyen-widrow mendapatkan rata-rata SMAPE yang lebih kecil dibandingkan dengan menggunakan bobot random dimana nilai rata-rata SMAPE terendah dengan menggunakan Nguyen-Widrow adalah 31.5736 sedangkan menggunakan bobot acak didapatkan rata-rata SMAPE terendah adalah 40.378.

6. DAFTAR PUSTAKA

- Abbas, Q., Ahmad, J. & Bangyal, W., H., 2010. Analysis of Learning Rate using BP Algorithm for Hand Written Digit Recognition Application, [e-journal]. Tersedia melalui: <<https://ieeexplore.ieee.org/abstract/document/5625732/>> [Diakses 3 Juni 2018].
- Andries, P., E., 2007. Computational Intelligence. South Africa: John Wiley & Sons.
- Andrian, Y., 2017. Analisis Algoritma Inisialisasi Nguyen-Widrow Pada Proses Prediksi Curah Hujan Kota Medan Menggunakan Metode Backpropagation Neural Network. Seminar Nasional Informatika, [e-journal] 1(4). Tersedia melalui: <<http://e-journal.potensi-utama.ac.id>> [Diakses 8 Mei 2018].
- Asthana, S., Pandit, A. & Bhardwaj, A., 2017. Analysis of Multiple Hidden Layer vs. Accuracy in Performance using Back Propagation Neural Network. Indian Journal of Science and Technology, [e-journal] 10(4). Tersedia melalui: <<http://www.indjst.org/index.php/indjst/article/view/110899>> [Diakses 3 Juni 2018].
- Cortez, P. & Morais, A.J.R., 2007. A Data Mining Approach to Predict Forest Fires Using Meteorological Data. Tersedia melalui: <<https://repositorium.sdum.uminho.pt>> [Diakses 7 Mei 2018].

- Dewi, C. & Muslikh, M., 2013. Perbandingan Akurasi Backpropagation Neural Network dan Anfis Untuk Memprediksi Cuaca. *Journal of Scientific Modeling & Computation*, [e-journal] 1(1). Tersedia melalui: <<http://natural-a.ub.ac.id>> [Diakses 7 Mei 2018].
- Flores, E., B., 1986. A Pragmatic View of Accuracy Measurement in Forecasting. *Omega Int J of Mgmt Sci*, [e-journal] 14(2). Tersedia melalui: <<https://www.sciencedirect.com>> [Diakses 8 Mei 2018].
- Hansun, S., 2013. Peramalan Data IHSG Menggunakan Metode Backpropagation. *ULTIMATICS*, [e-journal] 4(1). Tersedia melalui: <<http://ejournals.umn.ac.id>> [Diakses 7 Mei 2018].
- Jauhari, D., Himawan, A. & Dewi, C., 2016. Prediksi Distribusi Air PDAM Menggunakan Metode Jaringan Syaraf Tiruan Backpropagation Di PDAM Kota Malang. *Jurnal Teknologi Informasi dan Ilmu Komputer*, [e-journal] 3(2). Tersedia melalui: <<http://researchgate.net>> [Diakses 7 Mei 2018].
- Luthfianto, R., Santoso, I. & Christyono, Y., 2011. Peramalan Jumlah Penumpang Kereta Api Dengan Jaringan Saraf Tiruan Metode Perambatan Balik. Tersedia melalui: <<http://eprints.undip.ac.id>> [Diakses 7 Mei 2018].
- Margi, K.,S. & Pendawa, W., S., 2015. Analisa dan Penerapan Metode Single Exponential Smoothing Untuk Prediksi Penjualan Pada Periode Tertentu (Studi Kasus: PT. Media Cemara Kreasi). Tersedia melalui: <<http://jurnal.umk.ac.id>> [Diakses 8 Mei 2018].
- Matondang, ZA., 2013. Jaringan Syaraf Tiruan Dengan Algoritma Backpropagation Untuk Penentuan Kelulusan Sidang Skripsi. *Pelita Informatika Budi Darma*, [e-journal] 4(1). Tersedia melalui: <<http://www.stmik-budidarma.ac.id>> [Diakses 7 Mei 2018].
- Moyo, V. & Sibanda, K., 2015. Training Set Size for Generalization Ability of Artificial Neural Networks in Forecasting TCP/IP Traffic Trends. *International Journal of Computer Applications*, [e-journal] 113(13). Tersedia melalui: <<https://search.proquest.com/info/openurl/docerror;jsessionid=6C810FF20D2C97B8EA921E0B538E4F74.i-050821f3bd19644fa>> [Diakses 3 Juni 2018].
- Okine, A., 1999. Analysis of learning rate and momentum term in backpropagation neural network algorithm trained to predict pavement performance. Department of Civil and Environmental Engineering, Florida International University, Miami. [e-journal]. Tersedia melalui: <<https://www.sciencedirect.com/science/article/pii/S0965997898000714>> [Diakses 3 Juni 2018].
- Rasyid, F., 2014. Permasalahan dan Dampak Kebakaran Hutan. *Jurnal Lingkaran Widyaiswara*, [e-journal] 1(4). Tersedia melalui: <<http://juliwi.com>> [Diakses 8 Mei 2018].
- Siang, J., J., 2009. Jaringan Syaraf Tiruan dan Pemrograman Menggunakan Matlab. Yogyakarta: Andi Offset.
- Sinha, S., Singh T., N. & Verma, A., K., 2009. Epoch determination for neural network by self-organized map (SOM). [e-journal]. Tersedia melalui: <<https://link.springer.com/article/10.1007/s10596-009-9143-0>> [Diakses 3 Juni 2018].
- Suhartanto, S.,R., Dewi, C. & Muflikhah, L., 2017. Implementasi Jaringan Syaraf Tiruan Backpropagation untuk Mendiagnosis Penyakit Kulit pada Anak. *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, [e-journal] 1(7). Tersedia melalui: <<http://j-ptiik.ub.ac.id/index.php/j-ptiik/article/download/163/82/>> [Diakses 7 Mei 2018].
- WWF, 2007. Tentang Kehutanan, Air Tawar, dan Spesies. [online] Tersedia di: <https://www.wwf.or.id/tentang_wwf/upaya_kami/forest_spesies/tentang_forest_spesies/kehutanan/> [Diakses 8 Mei 2018].